

**Universidade Estácio de Sá
Niterói**

**Análise de Dados Big Data da Criminalidade no Estado do Rio de Janeiro de
2005 à 2015**

**Jeferson Luiz de Oliveira Junior
Roberto Magalhães da Cruz de Souza Campos**

Professor Orientador: Simone Gama

**2026
Niterói/RJ**

Sumário

1. DIAGNÓSTICO E TEORIZAÇÃO	3
1.1. Problemática e/ou problemas identificados.....	3
1.2. Justificativa	3
1.3. Objetivos/resultados/efeitos a serem alcançados (em relação ao problema identificado e sob a perspectiva dos públicos envolvidos).....	3
1.4. Referencial teórico (subsídio teórico para propositura de ações da extensão)	4
2. PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO	4
2.1. Plano de trabalho (usando ferramenta acordada com o docente)	4
2.2. Grupo de trabalho (descrição da responsabilidade de cada membro).....	4
2.3. Detalhamento técnico do projeto	5
3. ENCERRAMENTO DO PROJETO	6
3.1. Relato Coletivo:.....	6
3.1.1. CONSIDERAÇÕES FINAIS.....	6

1. DIAGNÓSTICO E TEORIZAÇÃO

1.1. Problemática e/ou problemas identificados

O Rio de Janeiro e suas regiões (Zonas Norte, Sul, Oeste e Centro) enfrentam grandes desafios na segurança pública. No entanto, o problema central deste projeto não é apenas a ocorrência dos crimes em si, mas a **difículdade de organizar e analisar os dados** gerados sobre eles.

Atualmente, as informações oficiais costumam ser divulgadas em planilhas desorganizadas, divididas em várias abas, com erros de formatação e dados repetidos. Isso torna a análise manual muito lenta e sujeita a falhas. Sem o uso de ferramentas de automação e Big Data, fica muito difícil para os gestores de segurança realizarem tarefas essenciais, como:

- **Identificar tendências:** Entender claramente se os crimes estão aumentando ou diminuindo ao longo dos anos.
- **Detectar anomalias (outliers):** Encontrar meses com números muito acima ou abaixo do normal, o que ajudaria a avaliar se uma operação policial funcionou ou falhou.
- **Mapear a concentração de crimes:** Visualizar o volume real de ocorrências para melhorar a distribuição de recursos e policiais nas ruas.

Portanto, o maior obstáculo é o atraso na análise: existe uma enorme quantidade de informações que, por falta de tratamento automático, não se transforma em conhecimento útil a tempo de ajudar na tomada de decisões contra a criminalidade.

1.2. Justificativa

A utilização de técnicas de Big Data e programação em Python permite organizar e analisar grandes volumes de registros criminais — como os dados de roubo de veículos — de forma rápida e eficiente.

Essa automatização transforma planilhas grande e difíceis de ler em gráficos e estatísticas claras. Com isso, o projeto ajuda a compreender melhor o comportamento da criminalidade nas diferentes regiões do Rio de Janeiro, apoiando as autoridades de segurança a tomarem as melhores decisões, inteligentes e baseadas em dados reais.

1.3. Objetivos/resultados/efeitos a serem alcançados (em relação ao problema identificado e sob a perspectiva dos públicos envolvidos)

Objetivo geral: Analisar a quantidade e a evolução das ocorrências criminais no Rio de Janeiro utilizando o cruzamento de dados reais.

Objetivos específicos:

- Preparar e limpar os dados confusos das planilhas originais.
- Calcular a média e a variação (desvio padrão) dos crimes registrados.
- Criar gráficos para analisar a distribuição de frequência das ocorrências.
- Aplicar o cálculo de regressão linear para identificar se a tendência dos crimes é de aumento ou queda.
- Identificar *outliers*, ou seja, detectar meses específicos que tiveram números de crimes muito acima ou muito abaixo do normal.
- Fonte: <https://datariov2-pcrj.hub.arcgis.com/documents/4c75c2e20d6146bfb77fd46b4373996e/about>

1.4. Referencial teórico (subsídio teórico para propositura de ações da extensão)

O projeto é baseado na aplicação de Big Data e Engenharia de Dados através da linguagem de programação Python. Para a análise, utiliza a estatística descritiva (médias e desvio padrão) e ferramentas matemáticas para criar gráficos, cálculo de regressão linear e detecção de anomalias (*outliers*).

2. PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO

2.1. Plano de trabalho (usando ferramenta acordada com o docente)

- Coleta de dados: Realização do download automático da planilha bruta com os registros criminais diretamente de um repositório na nuvem (GitHub).
- Limpeza dos dados: Remoção de linhas nulas, exclusão de cabeçalhos duplicados no meio da planilha e padronização das informações de meses e anos para facilitar a leitura.
- Análise descritiva: Transformação do formato original da tabela (pivotamento) para organizar os dados de forma clara por tipo de crime, região e quantidade, permitindo o cálculo de médias e variações.
- Geração de gráficos: Criação de recursos visuais, como o histograma, para demonstrar de forma acessível como o volume de ocorrências se distribui ao longo dos meses.
- Regressão linear: Aplicação de algoritmos matemáticos para traçar uma linha de tendência, revelando se os registros criminais estão em uma trajetória de aumento ou queda ao longo dos anos.
- Identificação de outliers: Utilização de regras estatísticas de desvio padrão para detectar anomalias, destacando os meses que apresentaram quantidades de crimes excessivamente altas ou baixas em relação à normalidade histórica.

2.2. Grupo de trabalho (descrição da responsabilidade de cada membro)

Projeto foi desenvolvido em dupla. O trabalho foi dividido de modo que cada membro teve suas responsabilidades bem definidas:

- **Roberto Magalhães:** Responsável pela Fase 1 (Engenharia de Dados e ETL), assumindo a responsabilidade pela extração via código, limpeza e estruturação da base de dados bruta original.
- **Jeferson Luiz:** Responsável pela Fase 2 (Ciência de Dados e Estatística), assumindo a responsabilidade pelo desenvolvimento do painel analítico interativo, cálculos estatísticos, regressão linear e geração visual dos gráficos.

2.3. Detalhamento técnico do projeto

i. Tema escolhido

O tema foi escolhido devido à relevância do problema da segurança pública no Rio de Janeiro e a necessidade de basear a tomada de decisão em dados.

ii. Código desenvolvido

O projeto foi implementado em Python utilizando bibliotecas como Pandas, NumPy, Matplotlib, Seaborn e Scikit-learn.

Repositorio Git : <https://github.com/RobertoM8/bigdata-em-pyhton/blob/main/trabalho>

iii. Resultados alcançados (Funcionamento Analítico)

O sistema processa os dados dinamicamente a partir da escolha do usuário, aplicando três métodos principais:

- **Análise Descritiva:** O código utiliza as funções matemáticas do Pandas (mean(), std(), min(), max()) para extrair e calcular a média mensal, o desvio padrão e os extremos de ocorrências de forma automática.
- **Regressão Linear:** O script agrupa os dados totais de cada **ano** e utiliza o Scikit-learn (LinearRegression()) para calcular o coeficiente angular, gerando um gráfico de dispersão com linha de regressão que aponta a tendência histórica (aumento ou queda) ao longo dos anos.
- **Outliers:** O sistema calcula um limite de tolerância (teto e piso baseados em 1.5 desvios padrões da média) e filtra a base de dados, indicando valores extremos. O código identifica e classifica como anomalias os meses específicos (junto aos seus respectivos anos) que registraram ocorrências fora do padrão histórico.

3. ENCERRAMENTO DO PROJETO

3.1. Relato Coletivo:

Os resultados indicam que o sistema desenvolvido é eficaz para o monitoramento da segurança pública, evidenciando as tendências criminais e a desigualdade entre as regiões da cidade. A ferramenta permite identificar claramente se as ocorrências estão aumentando ou diminuindo ao longo dos anos, além de apontar meses específicos com anomalias (*outliers*), facilitando a compreensão do cenário urbano e o planejamento de ações mais assertivas pelas autoridades.

3.1.1. CONSIDERAÇÕES FINAIS

A análise demonstrou a importância do uso de dados para compreensão de problemas urbanos, especialmente problemas ligados à segurança pública e à criminalidade. O pipeline desenvolvido em Python demonstrou que a automação e a estruturação de grandes volumes de informações são etapas essenciais para decisões estratégicas de forma rápida e precisa.